4 Experiment

Table 1a. 主实验结果计划表 · Qwen2.5-Omni-7B

Method	Pre-LLM Ratio	Final	FLOPs† (T)	FLOPs† Ratio	AVUT Human	World Sense	Video MME	MV Bench	LongVideo Bench	Daily Omni	Rel. Avg.
Full Tokens	100.00%	100.00%	841.21	100.00%	—	—	—	—	—	—	100%
Budget A · FLOPs† ≈ 35.90% · FRO final retention 45%											
Random	47.80%	47.80%	302.01	35.90%	—	—	—	—	—	—	—
FastV-AV	100.00%	32.27%	302.00	35.90%	—	—	—	—	—	—	—
FastVID-AV	47.80%	47.80%	302.01	35.90%	—	—	—	—	—	—	—
DyCoke-TTM-AV	47.80%	47.80%	302.01	35.90%	—	—	—	—	—	—	—
OmniZip	47.80%	47.80%	302.01	35.90%	—	—	—	—	—	—	—
OmniSelect	47.80%	47.80%	302.01	35.90%	—	—	—	—	—	—	—
OmniPack	57.04%	28.52%	301.98	35.90%	—	—	—	—	—	—	—
FRO (Ours)	**45.00%**	**45.00%**	**302.01**	**35.90%**	—	—	—	—	—	—	—
Budget B · FLOPs† ≈ 26.94% · FRO final retention 35%											
Random	38.12%	38.12%	226.58	26.93%	—	—	—	—	—	—	—
FastV-AV	100.00%	17.72%	226.58	26.93%	—	—	—	—	—	—	—
FastVID-AV	38.12%	38.12%	226.58	26.93%	—	—	—	—	—	—	—
DyCoke-TTM-AV	38.12%	38.12%	226.58	26.93%	—	—	—	—	—	—	—
OmniZip	38.12%	38.12%	226.58	26.93%	—	—	—	—	—	—	—
OmniSelect	38.12%	38.12%	226.58	26.93%	—	—	—	—	—	—	—
OmniPack	45.59%	22.79%	226.56	26.93%	—	—	—	—	—	—	—
FRO (Ours)	**35.00%**	**35.00%**	**226.58**	**26.94%**	—	—	—	—	—	—	—

两档按同模型 FRO 最终保留 45% / 35% 的 FLOPs† 设置目标；其他方法按整数 token 数反算保留率。Pre-LLM / Final 均相对原始音视频 token 数。

OmniPack：前端保留 2r，内部再保留 50%，最终为 r。FRO：独立评分前缀的开销另计，选出的 token 在进入主解码器前已压缩。

† 固定参考输入 32,000 个音视频 token + 256 个文本 token，100 步解码；计入主干及 FRO 可解析评分矩阵。AudioCLIP、聚类等额外开销 δ 尚未计入。

FLOPs† 匹配的是已计理论成本；性能待评测。AVUT 仅 Human；Video-MME / LongVideoBench 无字幕；Rel. Avg. 为六项相对性能的等权平均。

4 Experiment

Table 1b. 主实验结果计划表 · Qwen2.5-Omni-3B

Method	Pre-LLM Ratio	Final	FLOPs† (T)	FLOPs† Ratio	AVUT Human	World Sense	Video MME	MV Bench	LongVideo Bench	Daily Omni	Rel. Avg.
Full Tokens	100.00%	100.00%	487.34	100.00%	—	—	—	—	—	—	100%
Budget A · FLOPs† ≈ 31.79% · FRO final retention 45%											
Random	47.01%	47.01%	154.93	31.79%	—	—	—	—	—	—	—
FastV-AV	100.00%	34.53%	154.94	31.79%	—	—	—	—	—	—	—
FastVID-AV	47.01%	47.01%	154.93	31.79%	—	—	—	—	—	—	—
DyCoke-TTM-AV	47.01%	47.01%	154.93	31.79%	—	—	—	—	—	—	—
OmniZip	47.01%	47.01%	154.93	31.79%	—	—	—	—	—	—	—
OmniSelect	47.01%	47.01%	154.93	31.79%	—	—	—	—	—	—	—
OmniPack	53.51%	26.75%	154.93	31.79%	—	—	—	—	—	—	—
FRO (Ours)	**45.00%**	**45.00%**	**154.94**	**31.79%**	—	—	—	—	—	—	—
Budget B · FLOPs† ≈ 23.07% · FRO final retention 35%											
Random	37.31%	37.31%	112.43	23.07%	—	—	—	—	—	—	—
FastV-AV	100.00%	20.40%	112.44	23.07%	—	—	—	—	—	—	—
FastVID-AV	37.31%	37.31%	112.43	23.07%	—	—	—	—	—	—	—
DyCoke-TTM-AV	37.31%	37.31%	112.43	23.07%	—	—	—	—	—	—	—
OmniZip	37.31%	37.31%	112.43	23.07%	—	—	—	—	—	—	—
OmniSelect	37.31%	37.31%	112.43	23.07%	—	—	—	—	—	—	—
OmniPack	42.54%	21.27%	112.44	23.07%	—	—	—	—	—	—	—
FRO (Ours)	**35.00%**	**35.00%**	**112.44**	**23.07%**	—	—	—	—	—	—	—

两档按同模型 FRO 最终保留 45% / 35% 的 FLOPs† 设置目标；其他方法按整数 token 数反算保留率。Pre-LLM / Final 均相对原始音视频 token 数。

OmniPack：前端保留 2r，内部再保留 50%，最终为 r。FRO：独立评分前缀的开销另计，选出的 token 在进入主解码器前已压缩。

† 固定参考输入 32,000 个音视频 token + 256 个文本 token，100 步解码；计入主干及 FRO 可解析评分矩阵。AudioCLIP、聚类等额外开销 δ 尚未计入。

FLOPs† 匹配的是已计理论成本；性能待评测。AVUT 仅 Human；Video-MME / LongVideoBench 无字幕；Rel. Avg. 为六项相对性能的等权平均。

4.1 Experimental Settings

Benchmarks

- AVUT [5]：面向音频中心的视频理解，覆盖事件定位、对象匹配及信息提取等任务。
- WorldSense [4]：覆盖现实场景中的音视频感知与推理，检验联合模态理解能力。
- Video-MME [2]：覆盖短、中、长视频的多领域选择题评测，检验时长与内容泛化。
- MVBench [1]：通过二十类任务评测动作、事件顺序及时间关系理解。
- LongVideoBench [3]：评测长视频中的指代定位与细节推理，并提供视频与字幕交错输入。
- DailyOmni [6]：使用日常场景音视频选择题评测跨模态时间对齐、事件理解与推理。

Comparison Methods

- Full Tokens（Qwen2.5-Omni [11] · 代码）：完整保留共同预处理后的输入 token，作为准确率与成本基准。
- Random（参考论文 [13] · 参考代码）：对音视频 token 分别随机采样，作为无评分压缩对照。
- FastV-AV（论文 [7] · 代码）：使用语言模型浅层注意力选择 token，本计划扩展到音视频两种模态。
- FastVID-AV（论文 [10] · 代码）：结合关键帧选择与时空冗余压缩视频，音频采用统一均匀采样。
- DyCoke-TTM-AV（论文 [8] · 代码）：将时间 token 合并模块 TTM 应用于音频和视频。
- OmniZip（论文 [13] · 代码）：以音频显著性引导视频预算分配，并结合音频锚点合并与时空压缩。
- OmniSelect（论文 [14] · 代码）：使用 AudioCLIP 判断问题的模态偏好，动态选择音视频压缩策略。
- OmniPack（论文 [15] · 代码）：结合进入语言模型前的选择合并与模型内部剪枝，进行两阶段压缩。
- FRO (Ours)（本地代码）：结合跨视频证据与时间新颖性评分，在第 2 层特征评分后选择输入 token。

Implementation Details

统一配置

项目	本计划设置	参考依据
模型	Qwen2.5-Omni-3B / Qwen2.5-Omni-7B；同一模型各方法使用相同权重与 processor。	OmniZip [13] / OmniPack [15]
保留率	两档 FLOPs† 预算以 FRO 最终保留 45%、35% 为基准；其他方法使用主表反算的前端与最终保留率；文本完整保留。	OmniZip [13]；本计划统一最终预算
预算校准	固定参考输入下按整数 token 二分校准；各档已计 FLOPs† 与 FRO 目标偏差 <0.02%。正式评测按实际输入及完整评分开销重新校准。	本计划
双视频配对	沿用固定配对清单与原题；每对两路视频、两道题；所有模型、方法、档位共享配对。	既有配对协议
抽帧	候选帧率 2 fps；按下一页上限沿完整有效时间轴均匀抽帧。	OmniPack [15]
分辨率	每帧 max_pixels=128×28×28=100,352；保持原始宽高比。	OmniPack [15] / OmniSelect [14]
音频	16 kHz、单声道；每路最多 300 秒。长音频均匀取 60 段×5 秒，保留原时间戳并与视频对齐。	本计划；300 秒参考本地 processor 配置
配对输入预算	压缩前总输入 ≤32,256 token；超出时同比缩减两路帧数与音频片段数量，沿全时间轴重采样至满足预算。	本计划；依据模型 32,768 上下文配置
输入复用	共同预处理先生成固定输入；Full Tokens 与所有压缩方法读取相同输入、时间戳和提示词。	本计划
生成	每问题对 1 次确定性生成；do_sample=false，num_beams=1；最多生成 32 个 token。	参考 LMMs-Eval；本计划统一长度
随机性	配对与采样 seed=20261031；Random 使用该 seed 与 pair_id 的稳定哈希。	既有种子；本计划单次生成
精度与批量	BF16；batch_size=1 问题对/GPU；FlashAttention 2；需要显式注意力的评分步骤单独实现。	方法实现 + 本计划
硬件与调度	4×NVIDIA A100 PCIe 40GB；每卡一个进程；就绪队列按模型、方法、保留率与样本分片调度。	本机资源 / 工作区调度规范
数据执行	一个数据集完成全部配置并归档后清理媒体缓存，再下载下一数据集；结果、标注与配对清单保留。	既有执行协议

Implementation Details

Benchmark 输入与评分设置

Benchmark	完整评测范围	最大帧数	输出指标	参考依据
AVUT	Human：全部 1,734 题	128	Accuracy；六类任务分项	OmniPack [15] / OmniZip [13]
WorldSense	完整 test：3,172 题	128	Acc.；八领域分项	OmniPack [15]
Video-MME	完整 test：2,700 题	768	Acc.；短 / 中 / 长分项	OmniPack [15] / OmniZip [13]
LongVideoBench	完整 validation：1,337 题	256	Acc.；时长与任务分项	官方示例；本计划取长视频档
DailyOmni	完整评测集：1,197 题 / 684 视频	128	选项匹配 Accuracy；六类任务分项	OmniPack [15] / OmniSelect [14]

评分与统计口径

项目	设置
评测规模	六个评测集共 14,140 道原始问题；按数据集独立配对，共 7,071 个问题对；陪伴题不重复计分。
帧数口径	表中为每路视频的候选帧数上限；实际输入同时满足 32,256 token 配对预算。
有效时间范围	遵守 benchmark 的起止时间；抽帧与音频使用同一有效范围。
字幕与音频缺失	主表统一不输入字幕；无音轨时使用纯视频输入，所有方法共享该模态可用性。
选择题输出	输出 Q1:选项、Q2:选项；按各题原始选项集合解析；解析失败计错。
DailyOmni 计分	直接匹配预测选项与标准答案；1,197 题组成 599 个问题对，最后一个陪伴题 score_mask=0。
配对覆盖	每个原始问题计分一次；奇数题末尾配一个固定陪伴题，陪伴题 score_mask=0。
汇总与显著性	主表六个指标等权汇总相对得分；以视频对为簇进行 1,000 次 bootstrap，报告 FRO 与基线差值的 95% CI。

Implementation Details

方法配置与计算量统计

方法	压缩位置	预算规则	固定参数 / 执行方式
Full Tokens	全部保留	前端 100%；最终 100%	成本与准确率基准
Random	LLM 前	前端与最终均为 r；A/V 使用相同保留率	各模态均匀随机选择
FastV-AV	第 5 层注意力评分后	前端 100%；第 5 层后保留 r	采用 OmniZip 比较层位；早期完整序列计入 FLOPs
FastVID-AV	LLM 前	前端与最终均为 r；A/V 使用相同保留率	整段整数预算按时段分配；保留原排序与合并，校准最终视觉预算
DyCoke-TTM-AV	LLM 前	按主表反算最终预算 r	仅 TTM；整数分组尾部按稳定顺序补齐预算
OmniZip	LLM 前	按主表反算最终预算 r	计入音频锚点后校准；保持音频优先及时间窗分配
OmniSelect	LLM 前	按主表反算最终预算 r	保留 AudioCLIP、词性过滤与模态路由；计入辅助模型成本
OmniPack	前端 + 内部两阶段	前端 2r；内部保留 50%；最终 r	7B 第 18 层；3B 第 26 层；ηv/a=.25/.35，λ=.20，τv/a=.10/.05，ζ=.10
FRO (Ours)	独立第 2 层评分 → LLM 前选择	A 档 45%；B 档 35%；独立评分开销计入	bridge=.30；top-k=3；coverage=.20；novelty=.20；同模态跨路；原始嵌入重放

Efficiency Accounting

项目	统计设置
主表 FLOPs	主表两档对齐主解码器与 FRO 已计评分矩阵的 FLOPs†；完整成本再加各方法尚未计入的辅助开销 δ。
FLOPs 归一化	参考表按同模型、同输入 Full Tokens 归一化；正式评测再按每个数据集累计实际长度对应 FLOPs，并取六集比值的等权平均。
成本分项	单独记录主解码器、FRO 评分前缀、AudioCLIP、选择 / 合并；共同音视频编码器开销在端到端实测中计入。
延迟与显存	同卡型、batch_size=1；记录预处理、编码、评分 / 压缩、prefill、decode、峰值显存及问题对/小时。
FRO 无音频样本	按可用模态计算跨路支持；缺失模态不分配 token；冻结同一回退规则用于两个模型。

FLOPs Calculation

固定参考输入与统计口径

项目	计算设置
参考序列	N=32,256；音视频 32,000、文本 256；两路等长。FRO 两档主序列为 14,656 / 11,456；其他方法按对应预算反算长度。
生成预算	R = 100 个解码步用于 FLOPs 口径；实际选择题仍使用计划中的最多 32 个输出 token。
矩阵运算	1 MAC = 2 FLOPs；使用 GQA 的真实 K/V 维度与三投影 SwiGLU；注意力按稠密 N×N 矩阵乘法统计。
未计项目 δ	辅助模型 AudioCLIP、其他选择/聚类/合并矩阵及逐元素算子另行统计；共同音视频编码器、LM head、softmax、归一化与排序不在本参考表中。

计算公式

d：隐藏维度；m：FFN 中间维度；k：K/V 总维度；L：Transformer 层数。

$$A = 4d^2 + 4dk + 6dm$$

$$P(n) = An + 4dn^2$$

$$D(n) = RA + 4d[Rn + R(R+1)/2]$$

$$C = \Sigma_{\ell=1\ldots L} [P(n_\ell) + D(n_\ell)]$$

模型	L / d / m / k
7B	28 / 3,584 / 18,944 / 512
3B	36 / 2,048 / 11,008 / 256

方法层位与额外计算

方法	逐层输入与评分开销
前端压缩方法	全部 L 层使用 n = 256 + 32,000r；相同主干成本的不同方法，由额外选择成本 δ 区分。
FastV-AV	参考约定：前 5 层保留完整输入，后续层使用 n；解码时前 5 层保留完整 KV。实际实现以逐层记录替换。
OmniPack	前端保留 2r；7B 前 18 层 / 3B 前 26 层使用 256 + 64,000r，之后使用 n；对应早层 KV 保留前端长度。
FRO	主干全部使用 n；两路各额外执行第 1 层，再各取 32 个问题位置计算第 2 层 Q/K。跨路相似度先对 32 个锚点计算，再按模态筛选。

References

各组按论文首次公开日期排序；日期格式为年–月–日。

Benchmarks

[1] Kunchang Li et al. MVBench: A Comprehensive Multi-modal Video Understanding Benchmark. arXiv:2311.17005, 2023-11-28.

[2] Chaoyou Fu et al. Video-MME: The First-Ever Comprehensive Evaluation Benchmark of Multi-modal LLMs in Video Analysis. arXiv:2405.21075, 2024-05-31.

[3] Haoning Wu, Dongxu Li, Bei Chen, and Junnan Li. LongVideoBench: A Benchmark for Long-context Interleaved Video-Language Understanding. arXiv:2407.15754, 2024-07-22.

[4] Jack Hong et al. WorldSense: Evaluating Real-world Omnimodal Understanding for Multimodal LLMs. arXiv:2502.04326, 2025-02-06.

[5] Yudong Yang et al. Audio-centric Video Understanding Benchmark without Text Shortcut. arXiv:2503.19951, 2025-03-25.

[6] Ziwei Zhou, Rui Wang, Zuxuan Wu, and Yu-Gang Jiang. Daily-Omni: Towards Audio-Visual Reasoning with Temporal Alignment across Modalities. arXiv:2505.17862, 2025-05-23.

Methods

[7] Liang Chen et al. An Image is Worth 1/2 Tokens After Layer 2: Plug-and-Play Inference Acceleration for Large Vision-Language Models. arXiv:2403.06764, 2024-03-11.

[8] Keda Tao et al. DyCoke: Dynamic Compression of Tokens for Fast Video Large Language Models. arXiv:2411.15024, 2024-11-22.

[9] Leqi Shen et al. FastVID: Dynamic Density Pruning for Fast Video Large Language Models. arXiv:2503.11187, 2025-03-14.

[10] Jin Xu et al. Qwen2.5-Omni Technical Report. arXiv:2503.20215, 2025-03-26.

[11] Keda Tao et al. OmniZip: Audio-Guided Dynamic Token Compression for Fast Omnimodal Large Language Models. arXiv:2511.14582, 2025-11-18.

[12] Morunliu Yang et al. OmniSelect: Dynamic Modality-Aware Token Compression for Efficient Omni-modal Large Language Models. arXiv:2605.18041, 2026-05-18.

[13] Wanshun Su et al. OmniPack: Unified Token Compression for Efficient Omni-modal Large Language Models. arXiv:2608.03812, 2026-08-04.