4 Experiment

Table 1. Qwen2.5-Omni-7B · Accuracy (%)

Method	Final Retained	FLOPs / Full	CrossVid 2V-SC	X-Stream 2V-AV-SC*	CVBench 2V-SC	MVU-Eval 2V-SC	MVPBench 2V-SC	SYNCR 2V-SC
Full Tokens	100%	100%	—	—	—	—	—	—
Budget A · 匹配同样本 FRO 最终保留 45% 的计算预算								
Random	逐题校准	待实测	—	—	—	—	—	—
FastV-AV	逐题校准	待实测	—	—	—	—	—	—
FastVID-AV	逐题校准	待实测	—	—	—	—	—	—
DyCoke-TTM-AV	逐题校准	待实测	—	—	—	—	—	—
OmniZip	逐题校准	待实测	—	—	—	—	—	—
OmniSelect	逐题校准	待实测	—	—	—	—	—	—
OmniPack	逐题校准	待实测	—	—	—	—	—	—
FRO (Ours)	**45%**	**待实测**	**—**	**—**	**—**	**—**	**—**	**—**
Budget B · 匹配同样本 FRO 最终保留 35% 的计算预算								
Random	逐题校准	待实测	—	—	—	—	—	—
FastV-AV	逐题校准	待实测	—	—	—	—	—	—
FastVID-AV	逐题校准	待实测	—	—	—	—	—	—
DyCoke-TTM-AV	逐题校准	待实测	—	—	—	—	—	—
OmniZip	逐题校准	待实测	—	—	—	—	—	—
OmniSelect	逐题校准	待实测	—	—	—	—	—	—
OmniPack	逐题校准	待实测	—	—	—	—	—	—
FRO (Ours)	**35%**	**待实测**	**—**	**—**	**—**	**—**	**—**	**—**

- 2V-SC：原生恰好两路输入、一道单选题；同模型、同输入匹配 FLOPs，文本 token 全保留。
- 每模型 17 个配置；两个模型共 34 个配置。Final Retained 按实际可用音视频 token 计。
- FLOPs / Full 由各集合累计实际输入计算；保留率、耗时与显存另表报告。
- * X-Stream：Instant / Backward 的双路带音频单选子集，按提问时刻截断；离线前缀适配版。
- 主表待全部纳入样本完成后填报；中途比较只使用所有方法共同完成的题目。

4 Experiment

Table 1. Qwen2.5-Omni-3B · Accuracy (%)

Method	Final Retained	FLOPs / Full	CrossVid 2V-SC	X-Stream 2V-AV-SC*	CVBench 2V-SC	MVU-Eval 2V-SC	MVPBench 2V-SC	SYNCR 2V-SC
Full Tokens	100%	100%	—	—	—	—	—	—
Budget A · 匹配同样本 FRO 最终保留 45% 的计算预算								
Random	逐题校准	待实测	—	—	—	—	—	—
FastV-AV	逐题校准	待实测	—	—	—	—	—	—
FastVID-AV	逐题校准	待实测	—	—	—	—	—	—
DyCoke-TTM-AV	逐题校准	待实测	—	—	—	—	—	—
OmniZip	逐题校准	待实测	—	—	—	—	—	—
OmniSelect	逐题校准	待实测	—	—	—	—	—	—
OmniPack	逐题校准	待实测	—	—	—	—	—	—
FRO (Ours)	**45%**	**待实测**	**—**	**—**	**—**	**—**	**—**	**—**
Budget B · 匹配同样本 FRO 最终保留 35% 的计算预算								
Random	逐题校准	待实测	—	—	—	—	—	—
FastV-AV	逐题校准	待实测	—	—	—	—	—	—
FastVID-AV	逐题校准	待实测	—	—	—	—	—	—
DyCoke-TTM-AV	逐题校准	待实测	—	—	—	—	—	—
OmniZip	逐题校准	待实测	—	—	—	—	—	—
OmniSelect	逐题校准	待实测	—	—	—	—	—	—
OmniPack	逐题校准	待实测	—	—	—	—	—	—
FRO (Ours)	**35%**	**待实测**	**—**	**—**	**—**	**—**	**—**	**—**

- 2V-SC：原生恰好两路输入、一道单选题；同模型、同输入匹配 FLOPs，文本 token 全保留。
- 每模型 17 个配置；两个模型共 34 个配置。Final Retained 按实际可用音视频 token 计。
- FLOPs / Full 由各集合累计实际输入计算；保留率、耗时与显存另表报告。
- * X-Stream：Instant / Backward 的双路带音频单选子集，按提问时刻截断；离线前缀适配版。
- 主表待全部纳入样本完成后填报；中途比较只使用所有方法共同完成的题目。

4.1 Experimental Settings

Benchmarks

- CrossVid [3]：跨视频比较、时间理解和多视角推理；保留原生双视频单选题。
- X-Stream [6]：多路流式理解；保留带音频的双路即时 / 回溯单选题，使用可见历史前缀。
- CVBench [1]：跨视频对象关联、事件关联与复杂推理；保留双视频单选题。
- MVU-Eval [2]：多视频感知、空间关系和推理；筛选双视频单选任务，进行纯视觉评测。
- MVPBench [4]：多视频动作、质量及关系比较；按全部必需输入筛选原生双视频单选任务。
- SYNCR [5]：合成场景下的跨视频空间、运动和对象推理；保留双路单选四选一任务。

Comparison Methods

- Full Tokens（论文 [10] · 代码）：完整保留共享预处理输入。
- Random（参考论文 [13] · 参考代码）：按模态稳定随机采样，作为无评分压缩对照。
- FastV-AV（论文 [7] · 代码）：利用浅层注意力选择 token；本计划在第 5 层后剪枝。
- FastVID-AV（论文 [9] · 代码）：根据时段密度与冗余选择、合并视觉 token。
- DyCoke-TTM-AV（论文 [8] · 代码）：使用时间 token 合并模块 TTM，保留各组锚点。
- OmniZip（论文 [11] · 代码）：利用音频引导视觉预算，并压缩时间冗余。
- OmniSelect（论文 [12] · 代码）：结合 AudioCLIP、问题词性过滤与模态路由进行选择。
- OmniPack（论文 [13] · 代码）：组合前端选择合并和模型内部剪枝。
- FRO (Ours)（本地代码）：利用第 2 层特征、跨路支持及时间新颖性选择 token。

Implementation Details

统一模型、预算与生成设置

项目	本计划设置
模型	Qwen2.5-Omni-3B / 7B；各方法共享同一模型权重、processor 与输入缓存。
样本单位	一道官方题目 + 恰好两路视频；一次生成一个答案。保留原视频顺序、选项顺序及必要引用标记。
预算 A / B	FRO 最终保留 45% / 35%；其他方法按实际 token 数及辅助计算逐题校准至同模型 FRO FLOPs，偏差 ≤0.5%。
输出与评分	提示仅输出 Answer: A；允许选项编号按官方选项表一一映射。单次生成，精确选项匹配；不使用 LLM 裁判。
生成长度	max_new_tokens=64；do_sample=false；num_beams=1；不要求 CoT，不自动补答或重试答案。
上下文预算	压缩前总输入 ≤32,256 token，为输出和处理器边界预留空间；统一预处理后再比较各压缩方法。
超限处理	按相同系数缩减两路帧数 / 音频片段数量，沿有效时间范围均匀重采样；保留 stream ID、时间戳及必需题面信息，记录最终长度。
图像处理	按各集合的帧数与尺寸表处理；保留宽高比，使用同一 processor 的 28-pixel 对齐；固定帧索引，不按方法重抽帧。
音频	仅 X-Stream 主子集启用：16 kHz、单声道、原增益；按流独立输入，原时间轴对齐；其他五集主表为纯视觉。
精度与种子	BF16；batch_size=1 题/GPU；FlashAttention 2；seed=20261031；Random 以题目 ID 稳定派生种子。
推理调度	4×A100 PCIe 40GB；每卡一进程；就绪队列分片；模型常驻、跨题复用解码、CPU 异步预取。
版本与结果	新协议独立目录；固定标注版本、筛选清单及输入指纹。旧双题配对实验保留，准确率与 FLOPs 分开报告。

Implementation Details

按评测集设置输入参数

Benchmark	帧数 / 每路	尺寸 / 音频	原文依据与本计划选择
CrossVid	均匀 32 帧 双路共 64 帧	长边 360 纯视觉	附录 C、表 8 的 Omni-7B 使用 64 总帧并均分；3B 同配。论文 [3]
X-Stream	2 fps 候选 每路上限 128 帧	max_pixels=100,352 16 kHz 单声道	2 fps 来自数据预处理；128 帧与每路 120 秒音频为本计划。只在官方开始时刻到提问时刻内采样。论文 [6]
CVBench	均匀 8 帧 双路共 16 帧	max_pixels=200,704 纯视觉	§4.1 原设每视频 8 帧、448×448；本计划采用等面积上限并保留宽高比。论文 [1]
MVU-Eval	均匀 32 帧 双路共 64 帧	长边 720 纯视觉	附录 B.2.1 的 Qwen 系列使用每视频 32 帧、长边上限 720。论文 [2]
MVPBench	均匀 64 帧 双路共 128 帧	max_pixels=200,704 纯视觉	§IV-A 未给统一抽帧数；本计划选 64 帧以覆盖细粒度动作，448² 像素兼顾质量比较。论文 [4]
SYNCR	原生帧率 每路上限 128 帧	max_pixels=100,352 无音频	依据源片段 60 / 100 / 128 帧特点选定上限；按 start_sec / end_sec 裁剪，不将短片统一降到 2 fps。论文 [5]

X-Stream 时间与音频规则

项目	设置
子集名称	X-Stream-2V-AV-SC-Prefix；恰好两路、原生单选、Instant / Backward、至少一路有可解码音轨。两路均带音频另报子组。
可见时间	t≤ 官方提问时刻；保留跨流偏移与同步关系；禁止用答案证据区间缩短历史，Forward 不进入本主表。
长音频	每路 ≤120 秒保留全部；超出后沿可见前缀均匀选 24×5 秒，保留原始时间戳；输入超限再共同缩减。
指标	选项匹配 Accuracy；Instant / Backward 分项；解析失败率、截断率、音轨覆盖率。

Implementation Details

评测范围与筛选规则

项目	纳入规则
原生双视频	统计所有必需输入，包括参考视频、候选视频和裁剪片段；恰好两路，不从三 / 四路题中删视频凑成两路。
题型	明确的单选题、至少两个选项、唯一有效标准答案；保留原始选项与语义。开放题、多选集合题和自由排序输出不进入主表。
任务子集	使用发布评测 split 内全部符合条件的题；多个 split 分开记录，训练 / 开发数据不混入主表。
题量	六集筛选后的 N 均待标注清单统计；CrossVid 的 4,531 双视频题不能直接作为双视频单选题数。
缺失数据	分别记录符合条件、媒体可用、下载完成与评测完成的数量；缺失媒体不得被悄悄移出总分母。
输入身份	按 video ID、裁剪起止及流编号标识输入；同源不同片段遵守官方题目定义。保留 bbox、对象指代等必要元数据，并同步坐标变换。
视觉集合音轨	CrossVid / CVBench / MVU-Eval / MVPBench / SYNCR 主表禁用音频；可选音视频扩展单列，不混入纯视觉结果。
纳入清单冻结	记录官方版本 / commit、题目 ID、选项、答案索引、媒体映射与 SHA256；所有模型和方法共享同一题目集合。

评分与汇总

项目	设置
确定性解析	只解析唯一的 Answer: 标签或完整单选答案；允许官方编号 / 字母的一一映射；出现互相冲突选项时不猜测答案。
指标分母	Accuracy = 正确题数 / 全部纳入题数；无法解析计错，同时报告解析失败、空输出、长度截断和运行失败。
子任务	按官方类别报告准确率与题量；MVPBench 主表使用原始 Accuracy，原文归一化 proficiency 仅作单独补充指标。
比较与区间	中途只比较共同完成题目；最终对相同题目进行配对比较，以共享视频连通组为簇 bootstrap 1,000 次，报告 95% CI。
跨集合汇总	各集合独立报告；只有六集都完成且样本数非零时，计算六集 Accuracy 的等权平均。

Implementation Details

方法配置与预算校准

Method	固定设置
Full Tokens / Random	Full 保留共同输入全部 token；Random 按可用模态固定种子采样。
FastV-AV	第 5 层后剪枝；前 5 层完整计算、保留的 KV 与注意力评分计入 FLOPs。
FastVID-AV	全局整数视觉预算按时段分配；原有排序 / 合并；有音频时使用固定均匀音频基线。
DyCoke-TTM-AV	仅 TTM，保留组锚点并使用整数预算；不启用动态解码 KV 压缩。
OmniZip	有音频时启用音频引导；纯视觉输入使用明确的视觉路径，零音频 token，记录适配分支。
OmniSelect	有音频保留 AudioCLIP 与词性过滤；纯视觉时固定视觉路由，保留视觉选择核心；辅助调用按实际执行计成本。
OmniPack	前端选择 + 内部保留 50%；7B 第 18 层，3B 第 26 层；ηv/a=.25/.35，λ=.20，τv/a=.10/.05，ζ=.10。
FRO	独立第 2 层评分；bridge=.30，top-k=3，coverage=.20，novelty=.20；同模态跨路支持；选中原始嵌入送入主解码器。
无音频统一处理	不存在的模态预算为 0；不制造静音 token。新原生题目接口与无音频分支需在正式运行前完成适配验证。

FLOPs 与执行记录

项目	统计方式
目标	每题每模型先计算 FRO 45% / 35% 的成本目标，再对其他方法校准；不可达到的预算标为 infeasible，单独报告数量。
统计范围	1 MAC=2 FLOPs；主解码器 + 额外评分前缀 + AudioCLIP + 选择 / 合并矩阵运算；统一标准化 64 解码步，并另记实际生成成本。
共同编码器	压缩发生在编码后时，匹配预算不含共同编码器；端到端 FLOPs 与延迟另列并包含编码器。逐元素算子、排序等计数范围明确记录。
聚合	FLOPs Ratio = Σ方法成本 / Σ同输入 Full Tokens 成本；按集合、模型、档位分别算。不得复用旧固定参考输入的百分比。
吞吐与恢复	记录预处理、编码、评分、prefill、decode、峰值显存、题/小时；每卡独立输出，按题目 ID 去重，保留结果和输入指纹。

References

Benchmarks 在前、Methods 在后；各组按首次公开日期由早到晚排列。

Benchmarks

[1] Nannan Zhu et al. CVBench: Benchmarking Cross-Video Synergies for Complex Multimodal Reasoning. arXiv:2508.19542, 2025-08-27.

[2] Tianhao Peng et al. MVU-Eval: Towards Multi-Video Understanding Evaluation for Multimodal LLMs. arXiv:2511.07250, 2025-11-10.

[3] Jingyao Li et al. CrossVid: A Comprehensive Benchmark for Evaluating Cross-Video Reasoning in Multimodal Large Language Models. arXiv:2511.12263, 2025-11-15.

[4] Purui Bai et al. MVPBench: A Multi-Video Perception Evaluation Benchmark for Multi-Modal Video Understanding. arXiv:2603.22756, 2026-03-24.

[5] Sara Ghazanfari et al. SYNCR: A Cross-Video Reasoning Benchmark with Synthetic Grounding. arXiv:2605.08412, 2026-05-08.

[6] Peiwen Sun et al. X-Stream: Exploring MLLMs as Multiplexers for Multi-Stream Understanding. arXiv:2606.02482, 2026-06-01.

Methods

[7] Liang Chen et al. An Image is Worth 1/2 Tokens After Layer 2: Plug-and-Play Inference Acceleration for Large Vision-Language Models. arXiv:2403.06764, 2024-03-11.

[8] Keda Tao et al. DyCoke: Dynamic Compression of Tokens for Fast Video Large Language Models. arXiv:2411.15024, 2024-11-22.

[9] Leqi Shen et al. FastVID: Dynamic Density Pruning for Fast Video Large Language Models. arXiv:2503.11187, 2025-03-14.

[10] Jin Xu et al. Qwen2.5-Omni Technical Report. arXiv:2503.20215, 2025-03-26.

[11] Keda Tao et al. OmniZip: Audio-Guided Dynamic Token Compression for Fast Omnimodal Large Language Models. arXiv:2511.14582, 2025-11-18.

[12] Morunliu Yang et al. OmniSelect: Dynamic Modality-Aware Token Compression for Efficient Omni-modal Large Language Models. arXiv:2605.18041, 2026-05-18.

[13] Wanshun Su et al. OmniPack: Unified Token Compression for Efficient Omni-modal Large Language Models. arXiv:2608.03812, 2026-08-04.