4 Experiment

Table 1a. 主实验结果计划表 · Qwen2.5-Omni-7B

Method	Retained Ratio	FLOPs (T)	FLOPs Ratio	AVUT Human	World Sense	Video MME	MV Bench	LongVideo Bench	Daily Omni	Rel. Avg.
Full Tokens	100%	—	100%	—	—	—	—	—	—	100%
Random	45%	—	—	—	—	—	—	—	—	—
FastV-AV	45%	—	—	—	—	—	—	—	—	—
VisionZip-AV	45%	—	—	—	—	—	—	—	—	—
FastVID-AV	45%	—	—	—	—	—	—	—	—	—
VidCom²-AV	45%	—	—	—	—	—	—	—	—	—
DyCoke-TTM-AV	45%	—	—	—	—	—	—	—	—	—
OmniZip	45%	—	—	—	—	—	—	—	—	—
OmniSelect	45%	—	—	—	—	—	—	—	—	—
OmniPack	45%	—	—	—	—	—	—	—	—	—
FRO (Ours)	**45%**	—	—	—	—	—	—	—	—	—
Random	35%	—	—	—	—	—	—	—	—	—
FastV-AV	35%	—	—	—	—	—	—	—	—	—
VisionZip-AV	35%	—	—	—	—	—	—	—	—	—
FastVID-AV	35%	—	—	—	—	—	—	—	—	—
VidCom²-AV	35%	—	—	—	—	—	—	—	—	—
DyCoke-TTM-AV	35%	—	—	—	—	—	—	—	—	—
OmniZip	35%	—	—	—	—	—	—	—	—	—
OmniSelect	35%	—	—	—	—	—	—	—	—	—
OmniPack	35%	—	—	—	—	—	—	—	—	—
FRO (Ours)	**35%**	—	—	—	—	—	—	—	—	—

评测协议：双视频配对、两题联合回答；按原始问题分别计分。—：待评测。

AVUT 仅使用 Human；Video-MME 与 LongVideoBench 使用无字幕输入。

Rel. Avg. = 100 × 六个主表指标相对同模型 Full Tokens 得分之比的等权平均。

FLOPs Ratio：六个评测集计算量比值的等权平均。补充记录问题对双题全对率、各模态保留率与端到端延迟。

4 Experiment

Table 1b. 主实验结果计划表 · Qwen2.5-Omni-3B

Method	Retained Ratio	FLOPs (T)	FLOPs Ratio	AVUT Human	World Sense	Video MME	MV Bench	LongVideo Bench	Daily Omni	Rel. Avg.
Full Tokens	100%	—	100%	—	—	—	—	—	—	100%
Random	45%	—	—	—	—	—	—	—	—	—
FastV-AV	45%	—	—	—	—	—	—	—	—	—
VisionZip-AV	45%	—	—	—	—	—	—	—	—	—
FastVID-AV	45%	—	—	—	—	—	—	—	—	—
VidCom²-AV	45%	—	—	—	—	—	—	—	—	—
DyCoke-TTM-AV	45%	—	—	—	—	—	—	—	—	—
OmniZip	45%	—	—	—	—	—	—	—	—	—
OmniSelect	45%	—	—	—	—	—	—	—	—	—
OmniPack	45%	—	—	—	—	—	—	—	—	—
FRO (Ours)	**45%**	—	—	—	—	—	—	—	—	—
Random	35%	—	—	—	—	—	—	—	—	—
FastV-AV	35%	—	—	—	—	—	—	—	—	—
VisionZip-AV	35%	—	—	—	—	—	—	—	—	—
FastVID-AV	35%	—	—	—	—	—	—	—	—	—
VidCom²-AV	35%	—	—	—	—	—	—	—	—	—
DyCoke-TTM-AV	35%	—	—	—	—	—	—	—	—	—
OmniZip	35%	—	—	—	—	—	—	—	—	—
OmniSelect	35%	—	—	—	—	—	—	—	—	—
OmniPack	35%	—	—	—	—	—	—	—	—	—
FRO (Ours)	**35%**	—	—	—	—	—	—	—	—	—

评测协议：双视频配对、两题联合回答；按原始问题分别计分。—：待评测。

AVUT 仅使用 Human；Video-MME 与 LongVideoBench 使用无字幕输入。

Rel. Avg. = 100 × 六个主表指标相对同模型 Full Tokens 得分之比的等权平均。

FLOPs Ratio：六个评测集计算量比值的等权平均。补充记录问题对双题全对率、各模态保留率与端到端延迟。

4.1 Experimental Settings

Benchmarks

- AVUT [5]：面向音频中心的视频理解，覆盖事件定位、对象匹配及信息提取等任务。
- WorldSense [4]：覆盖现实场景中的音视频感知与推理，检验联合模态理解能力。
- Video-MME [2]：覆盖短、中、长视频的多领域选择题评测，检验时长与内容泛化。
- MVBench [1]：通过二十类任务评测动作、事件顺序及时间关系理解。
- LongVideoBench [3]：评测长视频中的指代定位与细节推理，并提供视频与字幕交错输入。
- DailyOmni [6]：使用日常场景音视频选择题评测跨模态时间对齐、事件理解与推理。

Comparison Methods

- Full Tokens（Qwen2.5-Omni [11] · 代码）：完整保留共同预处理后的输入 token，作为准确率与成本基准。
- Random（参考论文 [13] · 参考代码）：对音视频 token 分别随机采样，作为无评分压缩对照。
- FastV-AV（论文 [7] · 代码）：使用语言模型浅层注意力选择 token，本计划扩展到音视频两种模态。
- VisionZip-AV（论文 [9] · 代码）：保留视觉显著 token 并合并上下文 token，音频采用统一均匀采样。
- FastVID-AV（论文 [10] · 代码）：结合关键帧选择与时空冗余压缩视频，音频采用统一均匀采样。
- VidCom²-AV（论文 [12] · 代码）：通过时空压缩保留视频关键信息，音频采用统一均匀采样。
- DyCoke-TTM-AV（论文 [8] · 代码）：将时间 token 合并模块 TTM 应用于音频和视频。
- OmniZip（论文 [13] · 代码）：以音频显著性引导视频预算分配，并结合音频锚点合并与时空压缩。
- OmniSelect（论文 [14] · 代码）：使用 AudioCLIP 判断问题的模态偏好，动态选择音视频压缩策略。
- OmniPack（论文 [15] · 代码）：结合进入语言模型前的选择合并与模型内部剪枝，进行两阶段压缩。
- FRO (Ours)（本地代码）：结合跨视频证据与时间新颖性评分，在第 2 层特征评分后选择输入 token。

Implementation Details

统一配置

项目	本计划设置	参考依据
模型	Qwen2.5-Omni-3B / Qwen2.5-Omni-7B；同一模型各方法使用相同权重与 processor。	OmniZip [13] / OmniPack [15]
保留率	最终音视频 token 保留率 45%、35%；分母为共同预处理后的音视频 token，文本完整保留。	OmniZip [13]；本计划统一最终预算
预算校准	逐问题对校准；允许绝对误差 ≤0.5 个百分点；记录输入、前端与末层的 A/V token 数。	本计划
双视频配对	沿用固定配对清单与原题；每对两路视频、两道题；所有模型、方法、档位共享配对。	既有配对协议
抽帧	候选帧率 2 fps；按下一页上限沿完整有效时间轴均匀抽帧。	OmniPack [15]
分辨率	每帧 max_pixels=128×28×28=100,352；保持原始宽高比。	OmniPack [15] / OmniSelect [14]
音频	16 kHz、单声道；每路最多 300 秒。长音频均匀取 60 段×5 秒，保留原时间戳并与视频对齐。	本计划；300 秒参考本地 processor 配置
配对输入预算	压缩前总输入 ≤32,256 token；超出时同比缩减两路帧数与音频片段数量，沿全时间轴重采样至满足预算。	本计划；依据模型 32,768 上下文配置
输入复用	共同预处理先生成固定输入；Full Tokens 与所有压缩方法读取相同输入、时间戳和提示词。	本计划
生成	每问题对 1 次确定性生成；do_sample=false，num_beams=1；最多生成 32 个 token。	参考 LMMs-Eval；本计划统一长度
随机性	配对与采样 seed=20261031；Random 使用该 seed 与 pair_id 的稳定哈希。	既有种子；本计划单次生成
精度与批量	BF16；batch_size=1 问题对/GPU；FlashAttention 2；需要显式注意力的评分步骤单独实现。	方法实现 + 本计划
硬件与调度	4×NVIDIA A100 PCIe 40GB；每卡一个进程；就绪队列按模型、方法、保留率与样本分片调度。	本机资源 / 工作区调度规范
数据执行	一个数据集完成全部配置并归档后清理媒体缓存，再下载下一数据集；结果、标注与配对清单保留。	既有执行协议

Implementation Details

Benchmark 输入与评分设置

Benchmark	完整评测范围	最大帧数	输出指标	参考依据
AVUT	Human：全部 1,734 题	128	Accuracy；六类任务分项	OmniPack [15] / OmniZip [13]
WorldSense	完整 test：3,172 题	128	Acc.；八领域分项	OmniPack [15]
Video-MME	完整 test：2,700 题	768	Acc.；短 / 中 / 长分项	OmniPack [15] / OmniZip [13]
MVBench	完整 test：4,000 题	128	20 类任务准确率宏平均	本计划统一短视频预算；VidCom² [12]
LongVideoBench	完整 validation：1,337 题	256	Acc.；时长与任务分项	官方示例；本计划取长视频档
DailyOmni	完整评测集：1,197 题 / 684 视频	128	选项匹配 Accuracy；六类任务分项	OmniPack [15] / OmniSelect [14]

评分与统计口径

项目	设置
评测规模	六个评测集共 14,140 道原始问题；按数据集独立配对，共 7,071 个问题对；陪伴题不重复计分。
帧数口径	表中为每路视频的候选帧数上限；实际输入同时满足 32,256 token 配对预算。
有效时间范围	遵守 benchmark 的起止时间；抽帧与音频使用同一有效范围。
字幕与音频缺失	主表统一不输入字幕；无音轨时使用纯视频输入，所有方法共享该模态可用性。
选择题输出	输出 Q1:选项、Q2:选项；按各题原始选项集合解析；解析失败计错。
DailyOmni 计分	直接匹配预测选项与标准答案；1,197 题组成 599 个问题对，最后一个陪伴题 score_mask=0。
配对覆盖	每个原始问题计分一次；奇数题末尾配一个固定陪伴题，陪伴题 score_mask=0。
汇总与显著性	主表六个指标等权汇总相对得分；以视频对为簇进行 1,000 次 bootstrap，报告 FRO 与基线差值的 95% CI。

Implementation Details

方法配置与计算量统计

方法	压缩位置	45% 档	35% 档	固定参数 / 执行方式
Full Tokens	全部保留	100%	100%	成本与准确率基准
Random	LLM 前	45% A / 45% V	35% A / 35% V	各模态均匀随机选择
FastV-AV	第 5 层注意力评分后	总 A/V 45%	总 A/V 35%	采用 OmniZip 比较层位；早期完整序列计入 FLOPs
VisionZip-AV	LLM 前	V 45%；A 均匀 45%	V 35%；A 均匀 35%	保留显著与上下文选择机制；按整数预算分配
FastVID-AV	LLM 前	V 45%；A 均匀 45%	V 35%；A 均匀 35%	关键帧 / 非关键帧合计校准到最终视觉预算
VidCom²-AV	LLM 前	V 45%；A 均匀 45%	V 35%；A 均匀 35%	冻结时空选择规则，校准最终 token 数
DyCoke-TTM-AV	LLM 前	总 A/V 45%	总 A/V 35%	仅 TTM；整数分组尾部按稳定顺序补齐预算
OmniZip	LLM 前	ρa=0.30、ρv=0.60 起始	ρa=0.40、ρv=0.70 起始	计入音频锚点后校准；保持音频优先及时间窗分配
OmniSelect	LLM 前	总 A/V 45%	总 A/V 35%	保留 AudioCLIP、词性过滤与模态路由；计入辅助模型成本
OmniPack	前端 + 内部两阶段	90% × 50% =45%	70% × 50% =35%	7B 第 18 层；3B 第 26 层；ηv/a=.25/.35，λ=.20，τv/a=.10/.05，ζ=.10
FRO (Ours)	独立第 2 层评分 → LLM 前选择	最终 A/V 45%	最终 A/V 35%	bridge=.30；top-k=3；coverage=.20；novelty=.20；同模态跨路；原始嵌入重放

Efficiency Accounting

项目	统计设置
主表 FLOPs	按实际各层 token 数累计主解码器 prefill + 固定 100-token decode；加入独立评分、辅助模型与 token 选择计算；1 MAC=2 FLOPs。
FLOPs 归一化	每个数据集：该方法总 FLOPs / 同模型 Full Tokens 总 FLOPs；主表取六个数据集比值的等权平均。
成本分项	单独记录主解码器、FRO 评分前缀、AudioCLIP、选择 / 合并；共同音视频编码器开销在端到端实测中计入。
延迟与显存	同卡型、batch_size=1；记录预处理、编码、评分 / 压缩、prefill、decode、峰值显存及问题对/小时。
FRO 无音频样本	按可用模态计算跨路支持；缺失模态不分配 token；冻结同一回退规则用于两个模型。

References

各组按论文首次公开日期排序；日期格式为年–月–日。

Benchmarks

[1] Kunchang Li et al. MVBench: A Comprehensive Multi-modal Video Understanding Benchmark. arXiv:2311.17005, 2023-11-28.

[2] Chaoyou Fu et al. Video-MME: The First-Ever Comprehensive Evaluation Benchmark of Multi-modal LLMs in Video Analysis. arXiv:2405.21075, 2024-05-31.

[3] Haoning Wu, Dongxu Li, Bei Chen, and Junnan Li. LongVideoBench: A Benchmark for Long-context Interleaved Video-Language Understanding. arXiv:2407.15754, 2024-07-22.

[4] Jack Hong et al. WorldSense: Evaluating Real-world Omnimodal Understanding for Multimodal LLMs. arXiv:2502.04326, 2025-02-06.

[5] Yudong Yang et al. Audio-centric Video Understanding Benchmark without Text Shortcut. arXiv:2503.19951, 2025-03-25.

[6] Ziwei Zhou, Rui Wang, Zuxuan Wu, and Yu-Gang Jiang. Daily-Omni: Towards Audio-Visual Reasoning with Temporal Alignment across Modalities. arXiv:2505.17862, 2025-05-23.

Methods

[7] Liang Chen et al. An Image is Worth 1/2 Tokens After Layer 2: Plug-and-Play Inference Acceleration for Large Vision-Language Models. arXiv:2403.06764, 2024-03-11.

[8] Keda Tao et al. DyCoke: Dynamic Compression of Tokens for Fast Video Large Language Models. arXiv:2411.15024, 2024-11-22.

[9] Senqiao Yang et al. VisionZip: Longer is Better but Not Necessary in Vision Language Models. arXiv:2412.04467, 2024-12-05.

[10] Leqi Shen et al. FastVID: Dynamic Density Pruning for Fast Video Large Language Models. arXiv:2503.11187, 2025-03-14.

[11] Jin Xu et al. Qwen2.5-Omni Technical Report. arXiv:2503.20215, 2025-03-26.

[12] Xuyang Liu, Yiyu Wang, Junpeng Ma, and Linfeng Zhang. Video Compression Commander: Plug-and-Play Inference Acceleration for Video Large Language Models. arXiv:2505.14454, 2025-05-20.

[13] Keda Tao et al. OmniZip: Audio-Guided Dynamic Token Compression for Fast Omnimodal Large Language Models. arXiv:2511.14582, 2025-11-18.

[14] Morunliu Yang et al. OmniSelect: Dynamic Modality-Aware Token Compression for Efficient Omni-modal Large Language Models. arXiv:2605.18041, 2026-05-18.

[15] Wanshun Su et al. OmniPack: Unified Token Compression for Efficient Omni-modal Large Language Models. arXiv:2608.03812, 2026-08-04.